In [1]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
```

Steel Plate Defect Prediction

Kaggle competition 'Steel Plate Defect Prediction'

Описание исходного датасета:

Датасет содержит **27 признаков**, которые описывают стальные пластины и, связанные с ними измерения. В качестве ответа **7 классов**, которые указывают на наличие определенного дефекта.

Задача:

Построить модель многоклассовой классификации для прогнозирования дефектов стальных пластин

EDA

In [2]:
```
data = pd.read_csv('./train.csv')
```

In [3]:
```
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 19219 entries, 0 to 19218
Data columns (total 35 columns):
 #   Column                 Non-Null Count  Dtype  
---  ------                 --------------  -----  
 0   id                     19219 non-null  int64  
 1   X_Minimum              19219 non-null  int64  
 2   X_Maximum              19219 non-null  int64  
 3   Y_Minimum              19219 non-null  int64  
 4   Y_Maximum              19219 non-null  int64  
 5   Pixels_Areas           19219 non-null  int64  
 6   X_Perimeter            19219 non-null  int64  
 7   Y_Perimeter            19219 non-null  int64  
 8   Sum_of_Luminosity      19219 non-null  int64  
 9   Minimum_of_Luminosity  19219 non-null  int64  
 10  Maximum_of_Luminosity  19219 non-null  int64  
 11  Length_of_Conveyer     19219 non-null  int64  
 12  TypeOfSteel_A300       19219 non-null  int64  
 13  TypeOfSteel_A400       19219 non-null  int64  
 14  Steel_Plate_Thickness  19219 non-null  int64  
 15  Edges_Index            19219 non-null  float64
 16  Empty_Index            19219 non-null  float64
 17  Square_Index           19219 non-null  float64
 18  Outside_X_Index        19219 non-null  float64
 19  Edges_X_Index          19219 non-null  float64
 20  Edges_Y_Index          19219 non-null  float64
 21  Outside_Global_Index   19219 non-null  float64
 22  LogOfAreas             19219 non-null  float64
 23  Log_X_Index            19219 non-null  float64
 24  Log_Y_Index            19219 non-null  float64
 25  Orientation_Index      19219 non-null  float64
 26  Luminosity_Index       19219 non-null  float64
 27  SigmoidOfAreas         19219 non-null  float64
 28  Pastry                 19219 non-null  int64  
 29  Z_Scratch              19219 non-null  int64  
 30  K_Scatch               19219 non-null  int64  
 31  Stains                 19219 non-null  int64  
 32  Dirtiness              19219 non-null  int64  
 33  Bumps                  19219 non-null  int64  
 34  Other_Faults           19219 non-null  int64  
dtypes: float64(13), int64(22)
memory usage: 5.1 MB
```

Данные состоят из 34 колонок:

- 0 - id
- 1-27 - признаки
- 28-34 - таргеты

По информации видим, что все данные представлены в числовом виде.

In [4]:
```
# признаки (сразу убираем id)
```

```
features = data.columns[1:28]
# классы дефектов
targets = data.columns[28:]
```

Признаки

Посмотрим сводную статистику по признакам

In [5]:
```
data[features[0:10]].describe()
```

Out[5]:

	X_Minimum	X_Maximum	Y_Minimum	Y_Maximum	Pixels_Areas	X_Perimeter	Y_Perimeter	Sum_of_Luminos
count	19219.000000	19219.000000	1.921900e+04	1.921900e+04	19219.000000	19219.000000	19219.000000	1.921900e+
mean	709.854675	753.857641	1.849756e+06	1.846605e+06	1683.987616	95.654665	64.124096	1.918467e+
std	531.544189	499.836603	1.903554e+06	1.896295e+06	3730.319865	177.821382	101.054178	4.420247e+
min	0.000000	4.000000	6.712000e+03	6.724000e+03	6.000000	2.000000	1.000000	2.500000e+
25%	49.000000	214.000000	6.574680e+05	6.575020e+05	89.000000	15.000000	14.000000	9.848000e+
50%	777.000000	796.000000	1.398169e+06	1.398179e+06	168.000000	25.000000	23.000000	1.823800e+
75%	1152.000000	1165.000000	2.368032e+06	2.362511e+06	653.000000	64.000000	61.000000	6.797800e+
max	1705.000000	1713.000000	1.298766e+07	1.298769e+07	152655.000000	7553.000000	903.000000	1.159141e+

- "Y" признаки очень сильно выбиваются по масштабу - необходима нормировка данных
- max, min, sum, perimeter стоит проверить на корреляцию признаков

In [6]:
```
data[features[10:20]].describe()
```

Out[6]:

	Length_of_Conveyer	TypeOfSteel_A300	TypeOfSteel_A400	Steel_Plate_Thickness	Edges_Index	Empty_Index	Squar
count	19219.000000	19219.000000	19219.000000	19219.000000	19219.000000	19219.000000	19219
mean	1459.350747	0.402674	0.596337	76.213122	0.352939	0.409309	0
std	145.568687	0.490449	0.490644	53.931960	0.318976	0.124143	0
min	1227.000000	0.000000	0.000000	40.000000	0.000000	0.000000	0
25%	1358.000000	0.000000	0.000000	40.000000	0.058600	0.317500	0
50%	1364.000000	0.000000	1.000000	69.000000	0.238500	0.413500	0
75%	1652.000000	1.000000	1.000000	80.000000	0.656100	0.494600	0
max	1794.000000	1.000000	1.000000	300.000000	0.995200	0.927500	1

- "TypeOfSteel_A300", "TypeOfSteel_A400", возможно, бинарные признаки

In [34]:
```
data[features[20:]].describe()
```

Out[34]:

	Outside_Global_Index	LogOfAreas	Log_X_Index	Log_Y_Index	Orientation_Index	Luminosity_Index	SigmoidOfArea
count	19219.000000	19219.000000	19219.000000	19219.000000	19219.000000	19219.000000	19219.00000
mean	0.591899	2.473475	1.312667	1.389737	0.102742	-0.138382	0.57190
std	0.482050	0.760575	0.467848	0.405549	0.487681	0.120344	0.33221
min	0.000000	0.778200	0.301000	0.000000	-0.988400	-0.885000	0.11900
25%	0.000000	1.949400	1.000000	1.079200	-0.272700	-0.192500	0.25320
50%	1.000000	2.227900	1.146100	1.322200	0.111100	-0.142600	0.47290
75%	1.000000	2.814900	1.431400	1.707600	0.529400	-0.084000	0.99940
max	1.000000	4.554300	2.997300	4.033300	0.991700	0.642100	1.00000

- "LogOfAreas", "SigmoidOfAreas" - похожи на производные признаки от Areas, тоже стоит проверить на мультиколлинеарность

Вывод:

- нормировка
- проверка на мультиколлинеарность

Отрисуем признаки на графиках

In [8]:
```
fig, ax = plt.subplots(3,3,figsize=(18,10))
for i in range(len(features[:9])):
    sns.histplot(data[features[i]],ax=ax[i//3,i%3])
    ax[i//3,i%3].set_title(features[i])
    ax[i//3,i%3].set_ylabel(' ')
    ax[i//3,i%3].set_xlabel(' ')
```

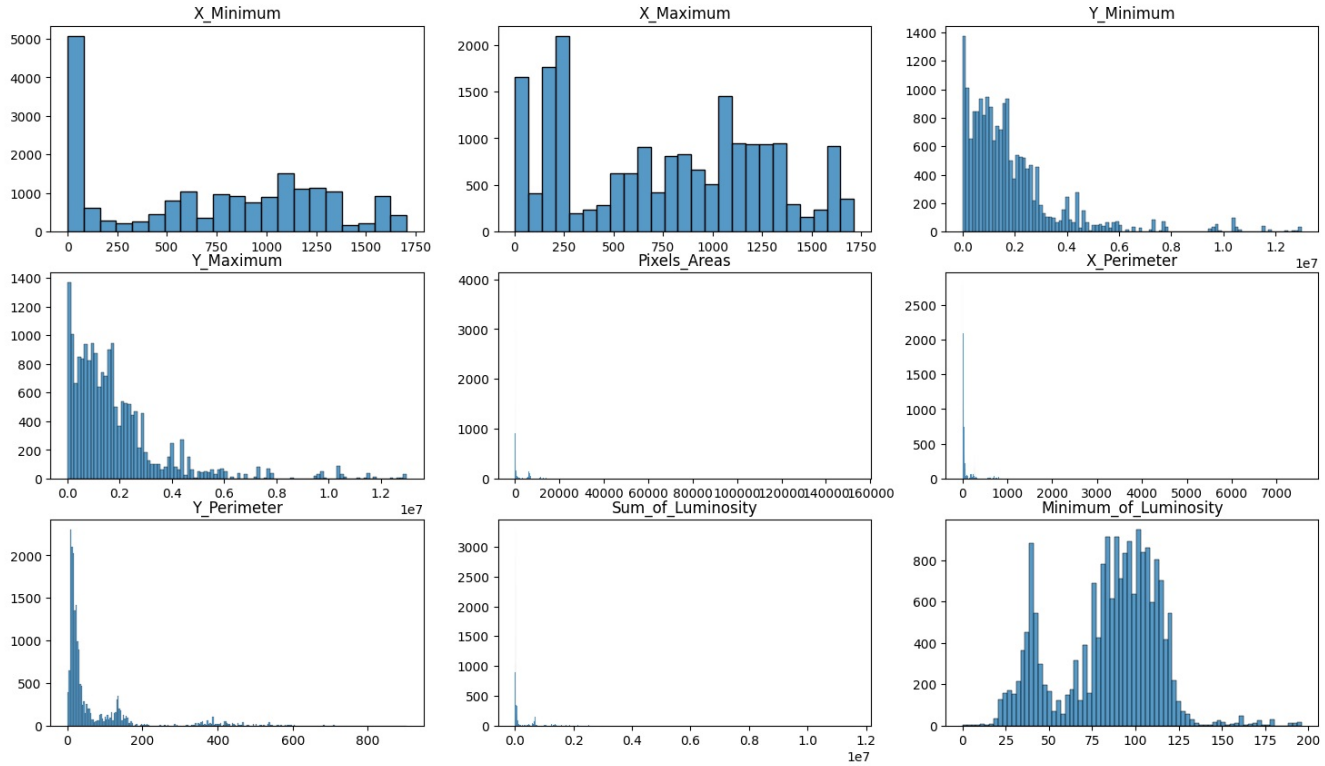

In [9]:
```
fig, ax = plt.subplots(3,3,figsize=(18,10))
for i in range(len(features[9:18])):
    sns.histplot(data[features[i+9]],ax=ax[i//3,i%3])
    ax[i//3,i%3].set_title(features[i+9])
    ax[i//3,i%3].set_ylabel(' ')
    ax[i//3,i%3].set_xlabel(' ')
```

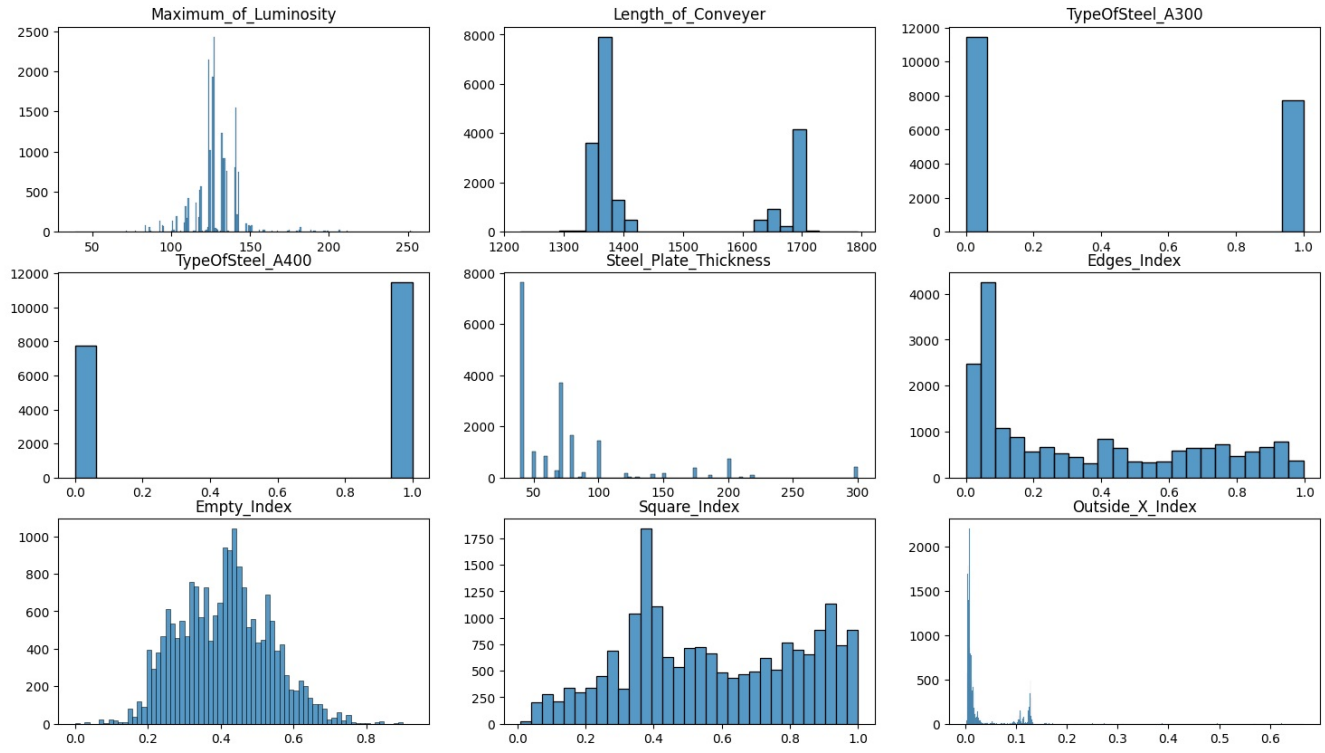

In [10]:
```
fig, ax = plt.subplots(3,3,figsize=(18,10))
for i in range(len(features[18:])):
    sns.histplot(data[features[i+18]],ax=ax[i//3,i%3])
    ax[i//3,i%3].set_title(features[i+18])
    ax[i//3,i%3].set_ylabel(' ')
```

```
    ax[i//3,i%3].set_xlabel(' ')
```

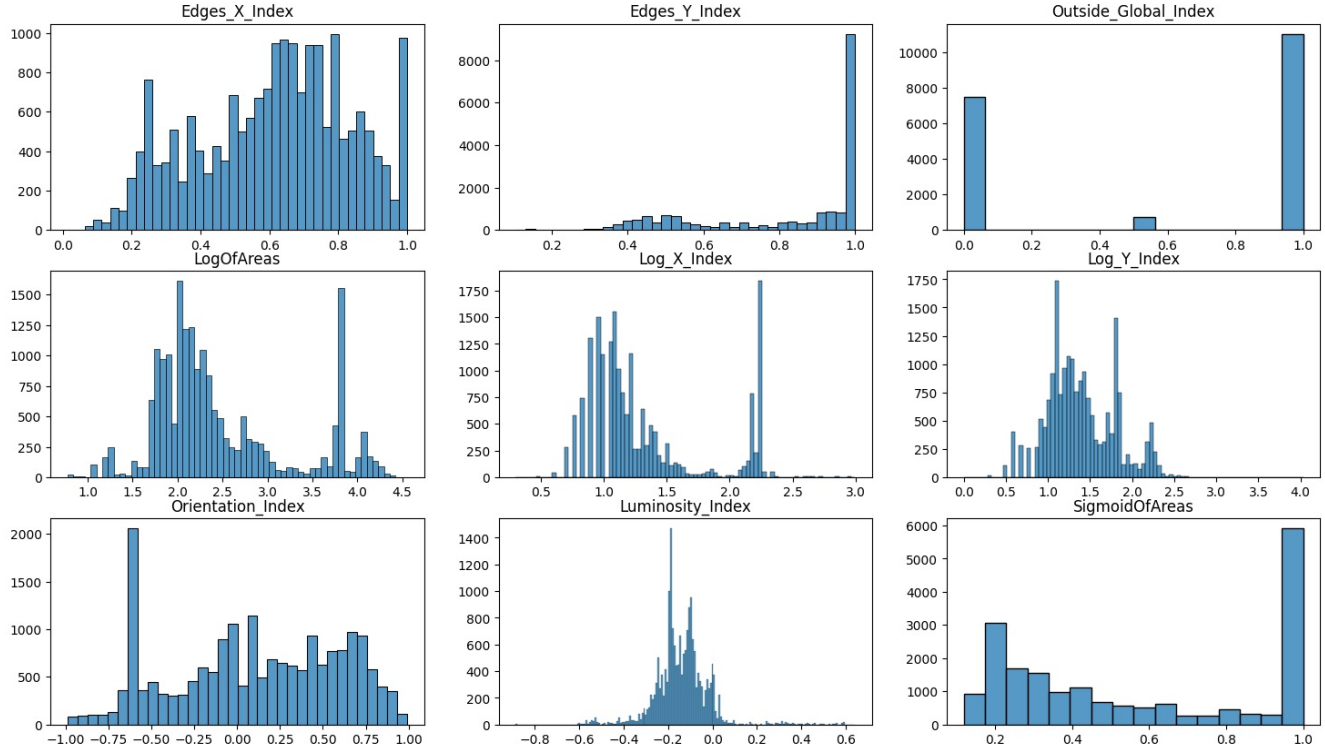

Вывод по графикам:

- "X_Perimeter", "Pixels_Areas", "Sum_Of_Luminosity" - проверить на выбросы
- "Outside_Global_Index" - категориальная (3 категории)?
- "TypeOfSteel_X" - бинарные

Выбросы

In [11]:
```
cols = "X_Perimeter", "Pixels_Areas", "Sum_of_Luminosity"
fig,ax = plt.subplots(1,3,figsize=(15,5))
for i in range(len(cols)):
    sns.boxplot(data[cols[i]],ax=ax[i])
```

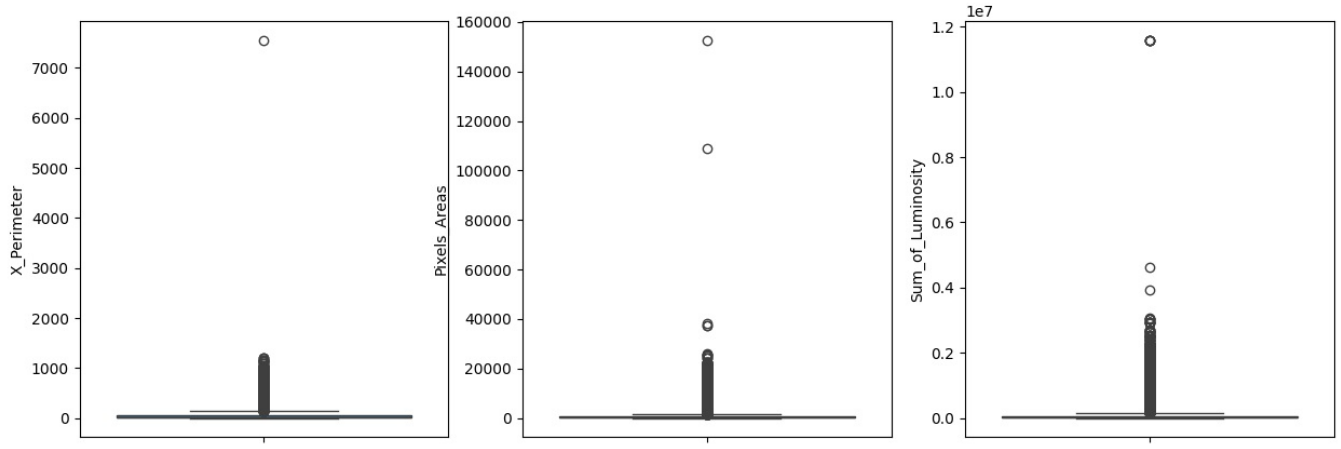

Посмотрим, что будет если отбросим 1% экстремальных значений

In [12]:
```
cols = "X_Perimeter", "Pixels_Areas", "Sum_of_Luminosity"
fig,ax = plt.subplots(1,3,figsize=(15,5))
k = int(data.shape[0]*0.99)
for i in range(len(cols)):
    sns.boxplot(data[cols[i]].sort_values()[:k],ax=ax[i])
```

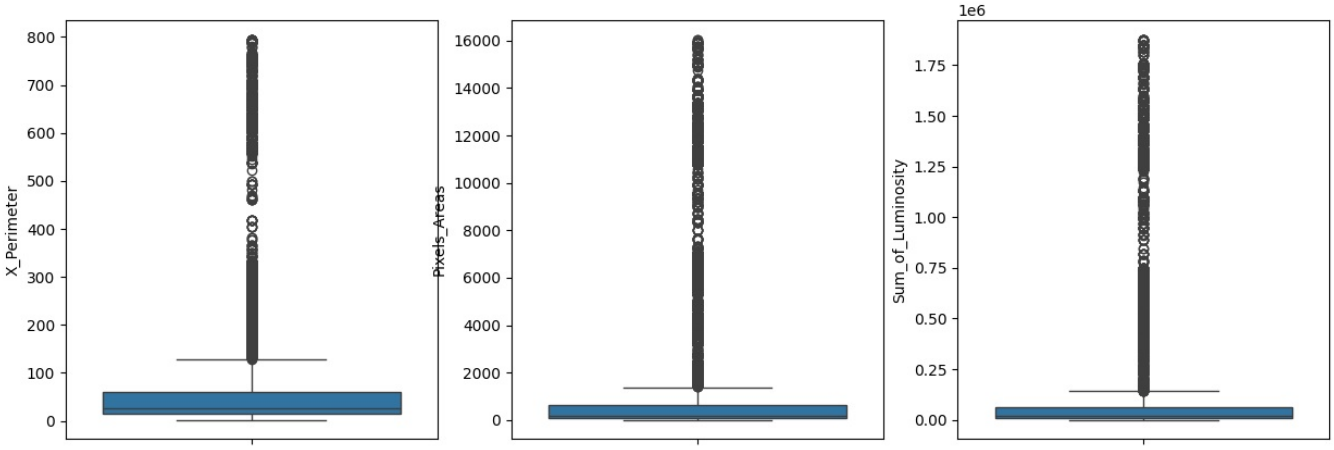

Графики получаются лучше, но теперь видно, что присутствсуют длинные "хвосты" распределения

Применим **log1p** преобразование

In [13]:
```
cols = "X_Perimeter", "Pixels_Areas", "Sum_of_Luminosity"
fig,ax = plt.subplots(1,3,figsize=(15,5))
for i in range(len(cols)):
    sns.boxplot(np.log1p(data[cols[i]]),ax=ax[i])
```

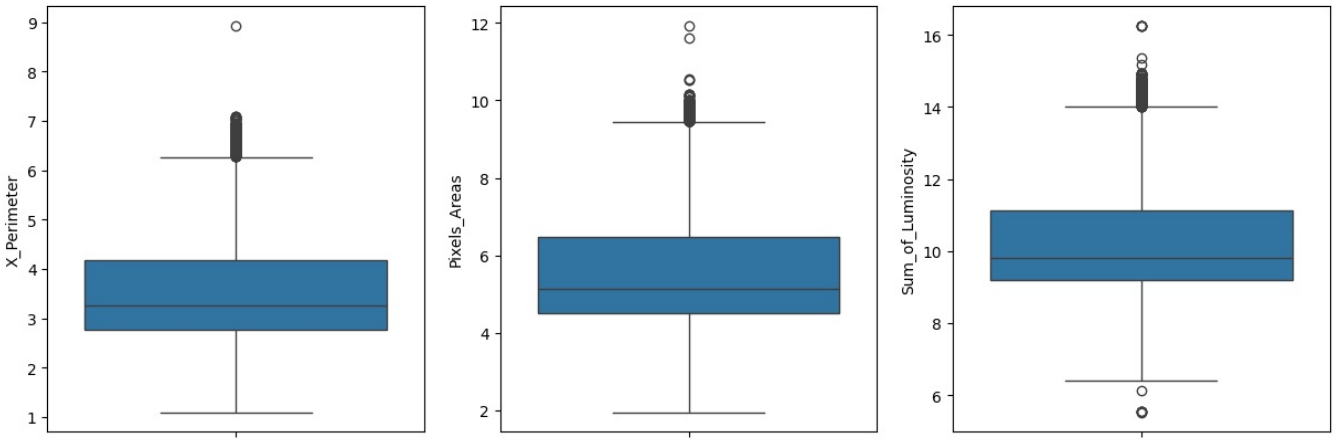

Вывод:

Думаю оставить строки, как есть, но применить к столбцам **log1p** преобразование, чтобы избавиться от влияние "хвостов"

Бинарные и категориальные переменные

In [14]:
```
feature = 'Outside_Global_Index'
data[feature].value_counts()
```

Out[14]:

Outside_Global_Index	count
1.0	11022
0.0	7490
0.5	706
0.7	1

dtype: int64

In [15]:
```
feature = 'TypeOfSteel_A300'
data[feature].value_counts()
```

Out[15]:

TypeOfSteel_A300	count
0	11480
1	7739

dtype: int64

In [16]:
```
feature = 'TypeOfSteel_A400'
data[feature].value_counts()
```

Out[16]:

TypeOfSteel_A400	count
1	11461
0	7758

dtype: int64

Вывод:

"TypeOfSteel_X" - бинарные

"Outside_Global_Index" - непонятен тип признака, возможно категориальный

Корреляция

Посчитаем корреляцию и выделим те значения, которые больше 80%

In [17]:
```
p = 0.8
sns.heatmap(data[features].corr(),mask=np.abs(data[features].corr())<p)
```

Out[17]:
```
<Axes: >
```

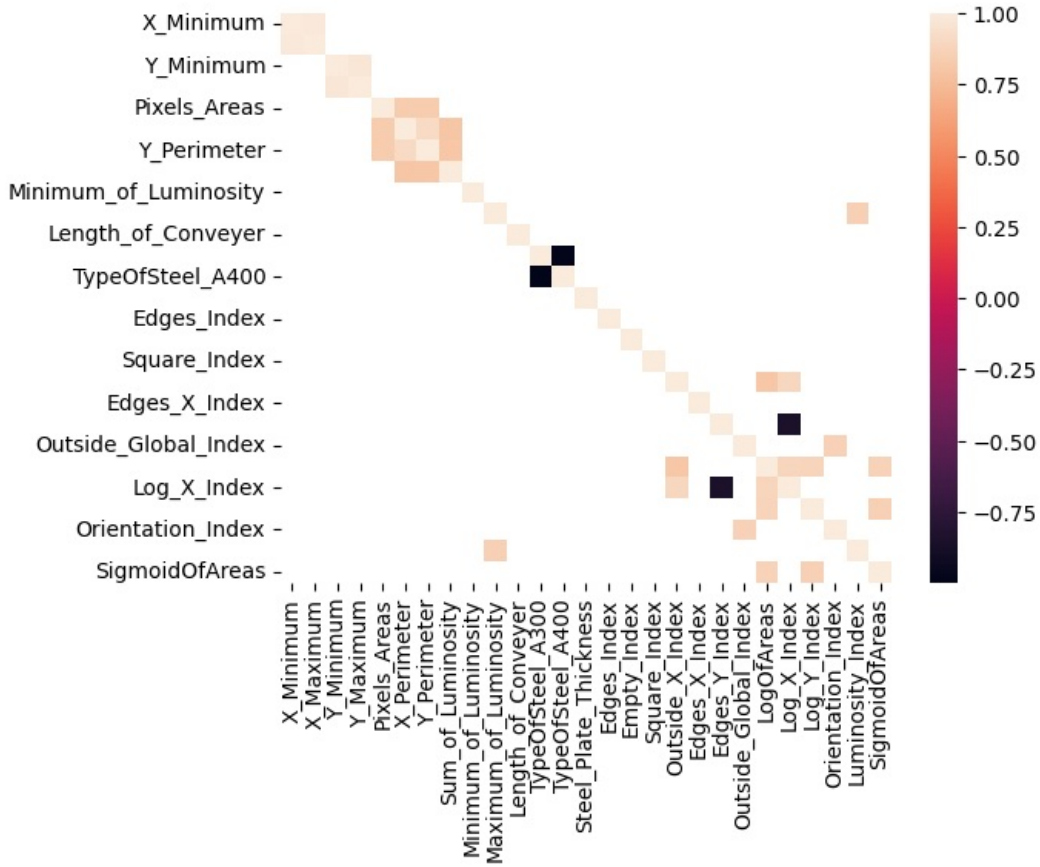

Посмотрим на все такие пары

In [18]:
```
data_corr = data[features].corr()
idx = np.where(np.abs(data_corr.mask(np.eye(len(data_corr), dtype=bool)))>p)

pairs = list(set(tuple(sorted(x)) for x in list(zip(idx[0], idx[1]))))
pd.Series(pairs)

for i,j in pairs:
    print(features[i],'\t\t',features[j],'\t\t',data_corr.loc[features[i],features[j]])
```

```
X_Minimum               X_Maximum               0.9897672786491646
LogOfAreas              SigmoidOfAreas                  0.8724531424401515
Outside_Global_Index            Orientation_Index               0.8639872069439484
Log_Y_Index             SigmoidOfAreas                  0.8524500761700224
Pixels_Areas            Y_Perimeter             0.8345434453321343
LogOfAreas              Log_X_Index             0.8882390325856594
Maximum_of_Luminosity           Luminosity_Index                0.8538555122645558
X_Perimeter             Sum_of_Luminosity               0.8020724927380157
Y_Minimum               Y_Maximum               0.9695524650996821
Y_Perimeter             Sum_of_Luminosity               0.8091705936142481
Pixels_Areas            X_Perimeter             0.835078733573749
TypeOfSteel_A300                TypeOfSteel_A400                -0.9977316148553689
Outside_X_Index                 Log_X_Index             0.8983409899912759
X_Perimeter             Y_Perimeter             0.9125793077170433
Edges_Y_Index           Log_X_Index             -0.8518128006577472
Outside_X_Index                 LogOfAreas              0.8119602292784268
LogOfAreas              Log_Y_Index             0.8792281394891333
```

In [19]:
```
indx_x = list(map(lambda x:(features[x[0]],features[x[1]]),pairs))
vals_x = list(map(lambda x:data_corr.loc[x[0],x[1]],indx_x))

pd.Series(data=vals_x,index=indx_x,name='corr').sort_values(ascending=False)
```

Out[19]:

	corr
(X_Minimum, X_Maximum)	0.989767
(Y_Minimum, Y_Maximum)	0.969552
(X_Perimeter, Y_Perimeter)	0.912579
(Outside_X_Index, Log_X_Index)	0.898341
(LogOfAreas, Log_X_Index)	0.888239
(LogOfAreas, Log_Y_Index)	0.879228
(LogOfAreas, SigmoidOfAreas)	0.872453
(Outside_Global_Index, Orientation_Index)	0.863987
(Maximum_of_Luminosity, Luminosity_Index)	0.853856
(Log_Y_Index, SigmoidOfAreas)	0.852450
(Pixels_Areas, X_Perimeter)	0.835079
(Pixels_Areas, Y_Perimeter)	0.834543
(Outside_X_Index, LogOfAreas)	0.811960
(Y_Perimeter, Sum_of_Luminosity)	0.809171
(X_Perimeter, Sum_of_Luminosity)	0.802072
(Edges_Y_Index, Log_X_Index)	-0.851813
(TypeOfSteel_A300, TypeOfSteel_A400)	-0.997732

dtype: float64

Вывод:

Координаты сильно коррелируют друг с другом, площадь и периметр коррелируют между собой

Думаю стоит преобразовать сильно коррелирующие столбцы в один, и удалить некоторые другие

In [ ]:
```
# X Y максимум и минимум
data_new = data[features]
data_new['X_sum'] = (data_new['X_Minimum'] + data_new['X_Maximum'])/2
data_new['Y_sum'] = (data_new['Y_Minimum'] + data_new['Y_Maximum'])/2

# периметер
data_new['Mean_perimeter'] = (data_new['X_Perimeter'] + data_new['Y_Perimeter'])/2

# удалим некоторые столбцы
data_new = data_new.drop(['LogOfAreas','Luminosity_Index','Log_Y_Index','Log_X_Index','Edges_Y_Index','Outside_

# удалим использованные
data_new = data_new.drop(['X_Minimum','X_Maximum','Y_Minimum','Y_Maximum','X_Perimeter','Y_Perimeter'],axis=1)
```

In [21]:
```
(data['TypeOfSteel_A300']+data['TypeOfSteel_A400']).value_counts()
```

Out[21]:

	count
1	19198
0	20
2	1

dtype: int64

Возможно данные зашумлены или есть какой-то 3 тип стали, думаю стоит удалить строки, где типы стали совпадают

In [22]:
```
data_new = data_new.drop(data[data['TypeOfSteel_A300']+data['TypeOfSteel_A400'] != 1].index)
data_new = data_new.drop('TypeOfSteel_A300',axis=1)
```

Еще раз проверим корреляцию признаков в новом датасете

In [23]:
```
p = 0.8
sns.heatmap(data_new.corr(),mask=np.abs(data_new.corr())<p)
```

Out[23]:
```
<Axes: >
```

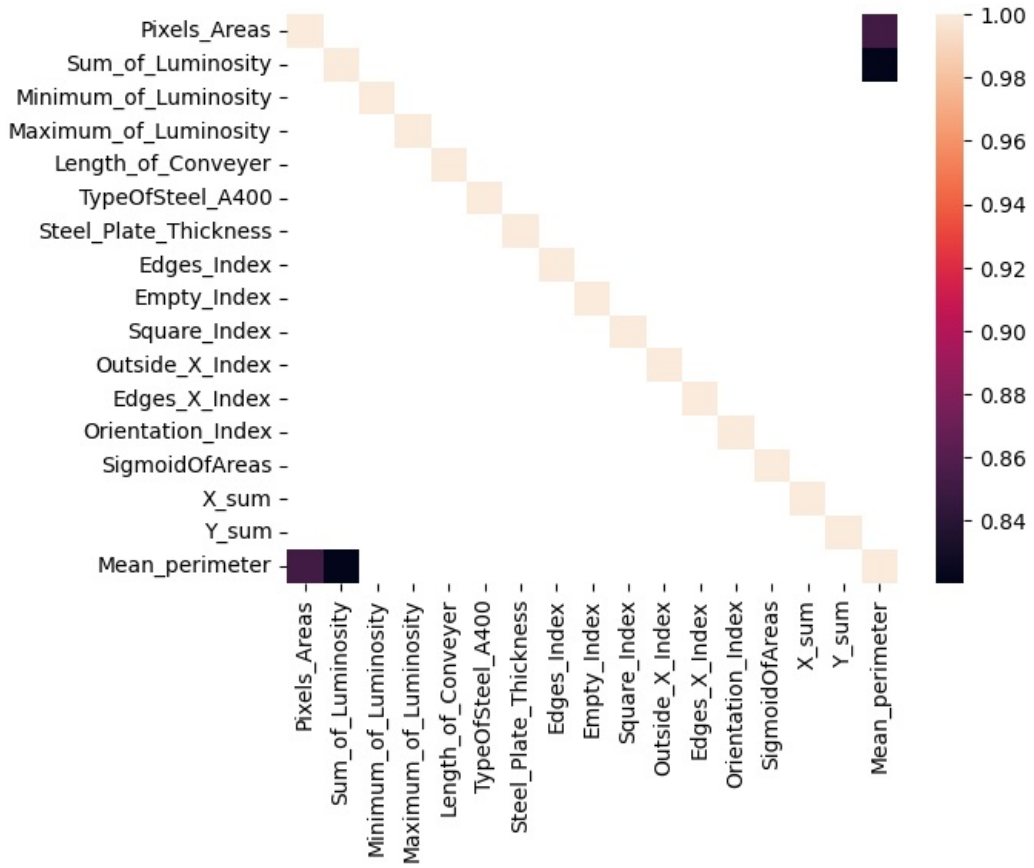

Вывод:

Думаю стоит убрать периметер вообще

Пропуски

In [24]:
```
data.isnull().sum().sum()
```

Out[24]:
```
np.int64(0)
```

Вывод:

Пропусков нет

Таргеты

In [25]:
```
data[targets].describe()
```

Out[25]:

	Pastry	Z_Scratch	K_Scatch	Stains	Dirtiness	Bumps	Other_Faults
count	19219.000000	19219.000000	19219.000000	19219.000000	19219.000000	19219.000000	19219.000000
mean	0.076279	0.059837	0.178573	0.029554	0.025235	0.247828	0.341225
std	0.265450	0.237190	0.383005	0.169358	0.156844	0.431762	0.474133
min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25%	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
50%	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
75%	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	1.000000
max	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000

По сводным статистикам ничего особенного нет

In [26]:
```
data[targets].sum(axis=1).value_counts()
```

Out[26]:

	count
1	18380
0	818
2	21

dtype: int64

Чаще всего в ответе 1 класс

In [27]:
```
sns.barplot(data[targets])
```

Out[27]:
```
<Axes: >
```

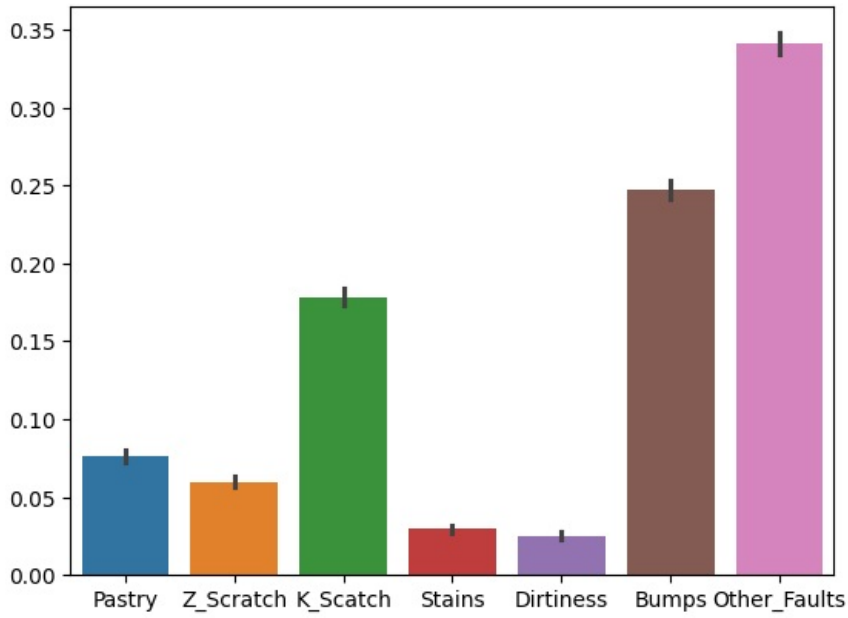

Видно, что классы плохо сбалансированы

In [27]:
```
```

Суммарный итог по EDA

- избавиться от мультиколлинеарности признаков
- пропусков в данных нет
- нормировка признаков
- не забывать про дисбаланс классов

Преобразования на основе EDA

In [28]:
```
def prepare_data(data,scalers,filename,train=True):
    data_new = data.copy()
```

```
    # X Y максимум и минимум
    data_new['X_sum'] = (data_new['X_Minimum'] + data_new['X_Maximum'])/2
    data_new['Y_sum'] = (data_new['Y_Minimum'] + data_new['Y_Maximum'])/2

    # периметер
    #data_new['Mean_perimeter'] = (data_new['X_Perimeter'] + data_new['Y_Perimeter'])/2

    # удалим некоторые столбцы
    data_new = data_new.drop(['LogOfAreas','Luminosity_Index','Log_Y_Index','Log_X_Index','Edges_Y_Index','Outs

    # удалим использованные
    data_new = data_new.drop(['X_Minimum','X_Maximum','Y_Minimum','Y_Maximum','X_Perimeter','Y_Perimeter'],axis

    data_new = data_new.drop(['id'],axis=1)

    # только для обучения
    if train:
        data_new = data_new.drop(data_new[data_new['TypeOfSteel_A300']+data_new['TypeOfSteel_A400'] != 1].index

    data_new = data_new.drop(['TypeOfSteel_A300'],axis=1)


    cols = ["Pixels_Areas", "Sum_of_Luminosity"]
    for col in cols:
        data_new[col] = np.log1p(data_new[col])

    # scale
    features = list(set(data_new.columns)-set(targets)-{'TypeOfSteel_A400'})
    features.sort()
    for scaler in scalers:
        if train:
            data_new[features] = scaler.fit_transform(data_new[features])
        else:
            data_new[features] = scaler.transform(data_new[features])

    #

    # save
    data_new.to_csv(filename,index=False)
```

In [29]:
```
test_data = pd.read_csv('test.csv')
```

In [30]:
```
from sklearn.preprocessing import MinMaxScaler, StandardScaler
scalers = [MinMaxScaler(feature_range=(-1, 1))]
scalers = [StandardScaler()]
prepare_data(data,scalers,'ready_train.csv')
prepare_data(pd.read_csv('./test.csv'),scalers,'ready_test.csv',train=False)
```

In [31]:
```
pd.read_csv('ready_test.csv')
```

Out[31]:

	Pixels_Areas	Sum_of_Luminosity	Minimum_of_Luminosity	Maximum_of_Luminosity	Length_of_Conveyer	TypeOfStee
0	0.455149	0.366509	-0.620536	-0.115630	1.349841	
1	0.124376	0.103994	0.248393	0.236473	-0.724051	
2	-0.017067	-0.061148	0.561207	0.377314	-0.682848	
3	-0.749448	-0.760497	0.769750	0.799838	1.583325	
4	-0.431151	-0.423867	0.630722	0.377314	1.569591	
...	...	...	...	...	...	
12809	0.028590	-0.236041	-0.203450	-1.805724	-0.730918	
12810	-0.921775	-1.040179	0.978293	0.870258	-0.669114	
12811	2.306449	2.296038	-2.115094	1.011099	-0.408160	
12812	0.148621	0.067892	-0.655293	-0.326892	-0.655379	
12813	1.670664	1.636196	-1.628494	0.870258	-0.710317	

12814 rows × 16 columns

In [31]:

Обучение модели на основе нейронной сети

In [23]:
```
import torch
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from torch.utils.data import DataLoader, Dataset

import torchvision
import torchvision.transforms as transforms

import torch.nn as nn
import torch.nn.functional as F

from sklearn.model_selection import train_test_split
from sklearn.metrics import roc_auc_score

from sklearn.metrics import RocCurveDisplay
from sklearn.metrics import ConfusionMatrixDisplay
```

In [24]:
```
targets = ['Pastry','Z_Scratch','K_Scatch','Stains','Dirtiness','Bumps','Other_Faults']
data = pd.read_csv('./ready_train.csv')

features = list(set(list(data.columns)) - set(targets))
```

Dataset и DataLoader

In [25]:
```
from imblearn.under_sampling import RandomUnderSampler

class SteelPlateDataset(Dataset):
    def __init__(self,X,y=None,balance=False):
        if balance:
            rus = RandomUnderSampler()
            self.X, self.y = rus.fit_resample(X, y)
        else:
            self.X = X
            self.y = y

    def __len__(self):
        return len(self.X)

    def __getitem__(self, index):
        if self.y is not None:
            return self.X.iloc[index].values.astype(np.float32),self.y.iloc[index].astype(np.float32).reshape((

        return self.X.iloc[index].values.astype(np.float32)
```

Построение структуры нейросети

Для каждого класса будем строить свою модель обучения

Функции активации Relu, на последнем сигмоида, которая даст вероятность обнаружение данного класса дефекта.

In [26]:
```
class Net(nn.Module):
    def __init__(self,input_size):
        super(Net, self).__init__()

        self.mainSeq = nn.Sequential(
            nn.Linear(input_size,64),
            nn.ReLU(),

            nn.Linear(64,32),
            nn.ReLU(),

            nn.Linear(32,1),
            nn.Sigmoid()
        )

    def forward(self, x):

       return self.mainSeq(x)
```

Обучение

Глобальные параметры для обучения

In [27]:
```
# параметры
EPOCHS = 50
LEARNING_RATE = 1e-4
#
```

Функция для обучения модели предсказания для 1 класса

In [28]:
```
from tqdm import tqdm

def train_one_class(model,optimizer,criterion,train_loader,val_loader=None):

    train_tqdm = tqdm(range(EPOCHS))
    train_errors = []
    val_errors = []
    for epoch in train_tqdm:
        # train step
        model.train()
        train_loss = 0
        for X, y in train_loader:
            optimizer.zero_grad()
            output = model(X)
            loss = criterion(output, y)
            loss.backward()
            optimizer.step()
            train_loss += loss.item()
        train_loss = train_loss / len(train_loader.dataset)
        train_errors.append(train_loss)

        train_tqdm.set_description(f"Loss = {train_loss:.5}")
        # val step
        val_loss = 0
        if val_loader is not None:
            model.eval()
            for X, y in val_loader:
                output = model(X)
                loss = criterion(output, y)
                val_loss += loss.item()
            val_loss = val_loss / len(val_loader.dataset)
            val_errors.append(val_loss)

            train_tqdm.set_description(f"Loss = {train_loss:.5}, Val = {val_loss:.5}")

    return [train_errors,val_errors]
```

Цикл для обучения по всем классам

Используем **BCELoss**, т.к. для каждого класса строим свой классификатор, соответственно бинарная кросс энтропия в качестве функции потерь

В качестве оптимизатора **Адам**

Количество **Эпох** и **Скорость обучения** выбраны экспериментальным путем

In [29]:
```
def train_one(y_class):

    #
    X_train, X_val, y_train, y_val = train_test_split(data[features], data[y_class], test_size=0.3, stratify=da

    train_data = SteelPlateDataset(X_train,y_train,balance=True)
    val_data = SteelPlateDataset(X_val,y_val)

    train_loader = torch.utils.data.DataLoader(train_data, batch_size=32)
    val_loader = torch.utils.data.DataLoader(val_data, batch_size=32)
    #
    model = Net(X_train.shape[1])

    criterion = nn.BCELoss()
    optimizer = torch.optim.Adam(model.parameters(), lr=LEARNING_RATE, weight_decay=0.01)

    err = train_one_class(model,optimizer,criterion,train_loader,val_loader)
    preds = None
    y_true = None
    model.eval()
    for x,y in val_loader:
        if preds is None:
            preds = model(x).detach().numpy()
            y_true = y
        else:
            preds = np.vstack([preds,model(x).detach().numpy()])
            y_true = np.vstack([y_true,y])

    rcs = roc_auc_score(y_val,preds).item()
    print(rcs)
    return model,err
```

In [30]:
```
def train_all():
    models = list()
    errors = list()
    for y_class in targets:
        model,err = train_one(y_class)

        models.append(model)
        errors.append(err)
    return models,errors
```

Параллельная версия функции обучения для ускорения

In [31]:
```
import multiprocessing as mp
import time

def process_train_one(y_class):
    model,err = train_one(y_class)
    return y_class, model, err

def train_all_parallel():
    start_time = time.time()

    # Создание пула процессов
    with mp.Pool(processes=7) as pool:
        # Список асинхронных задач
        async_results = []

        # Запускаем каждую задачу асинхронно
        for i in range(7):
            async_result = pool.apply_async(process_train_one, args=(targets[i],))
            async_results.append(async_result)

        # Собираем результаты
        results = [async_result.get() for async_result in async_results]

    end_time = time.time()
    total_time = end_time - start_time
    print(f"Время выполнения: {total_time:.2f} секунд")
    models = list()
    errors = list()
    d = dict()

    for i in range(len(targets)):
        y_class,model,err = results[i]
        d[y_class] = model,err

    for i in range(len(targets)):
        models.append(d[targets[i]][0])
        errors.append(d[targets[i]][1])
    #
    return models,errors
```

In [32]:
```
models,errors = train_all_parallel()
```

```
Loss = 0.018042, Val = 0.019319: 100%|██████████| 50/50 [03:51<00:00,  4.64s/it]
Loss = 0.018402, Val = 0.019193:  44%|████      | 22/50 [03:56<04:57, 10.63s/it]
0.863028339132599
Loss = 0.008187, Val = 0.0099902: 100%|██████████| 50/50 [04:01<00:00,  4.83s/it]
Loss = 0.013152:  86%|████████  | 43/50 [04:03<00:36,  5.25s/it]
0.9776491634220772
Loss = 0.012764, Val = 0.013391: 100%|██████████| 50/50 [04:31<00:00,  5.44s/it]
Loss = 0.018322:  52%|█████     | 26/50 [04:33<03:26,  8.60s/it]
0.9030861669811446
Loss = 0.015856, Val = 0.016568: 100%|██████████| 50/50 [04:43<00:00,  5.67s/it]
Loss = 0.020117, Val = 0.020443:  46%|████      | 23/50 [04:44<04:15,  9.45s/it]
0.8401854066985647
Loss = 0.0054678, Val = 0.0064049: 100%|██████████| 50/50 [05:36<00:00,  6.72s/it]
Loss = 0.018173, Val = 0.019099:  82%|████████  | 41/50 [05:36<00:35,  3.99s/it]
0.9753697169495456
Loss = 0.018101, Val = 0.019072: 100%|██████████| 50/50 [06:02<00:00,  7.25s/it]
Loss = 0.020007:  80%|████████  | 40/50 [06:02<00:35,  3.59s/it]
0.747454313694347
Loss = 0.020028, Val = 0.020347: 100%|██████████| 50/50 [06:21<00:00,  7.64s/it]
0.682805842941624
Время выполнения: 383.24 секунд
```

Сохраним модели

In [33]:
```
def save_model(model,file_path):
    torch.save(model.state_dict(), file_path)
```

In [34]:
```
for i in range(len(targets)):
    save_model(models[i],f'./{targets[i]}.model')
```

Метрики качества

Отрисовывает:

1. Кривые ошибки на обучении и валидации
2. AUC ROC

In [35]:
```
def plot_metrics(model,y_class,train_error,val_error):
    X,y = data[features],data[y_class]
    x_loader = torch.utils.data.DataLoader(SteelPlateDataset(X,y), batch_size=len(X))
    with torch.no_grad():
        for d,_ in x_loader:
            pred = model(d).detach().numpy()

    fig,ax = plt.subplots(1,2,figsize=(15,5))

    # lineplot
    sns.lineplot(train_error,c='b',ax=ax[0],label='Train')
    sns.lineplot(val_error,c='r',ax=ax[0],label='Val')
    ax[0].set(xlabel='Epochs',ylabel='Error', title='Model errors')
    # roc auc
    rcs = roc_auc_score(y,pred)

    display = RocCurveDisplay.from_predictions(y,pred,name=y_class,color="darkorange",plot_chance_level=True,de
    _ = display.ax_.set(xlabel="FPR", ylabel="TPR", title=f"ROC AUC for {y_class} with {rcs:.4} score")
```

In [36]:
```
i = 0
plot_metrics(models[i],targets[i],errors[i][0],errors[i][1])
```

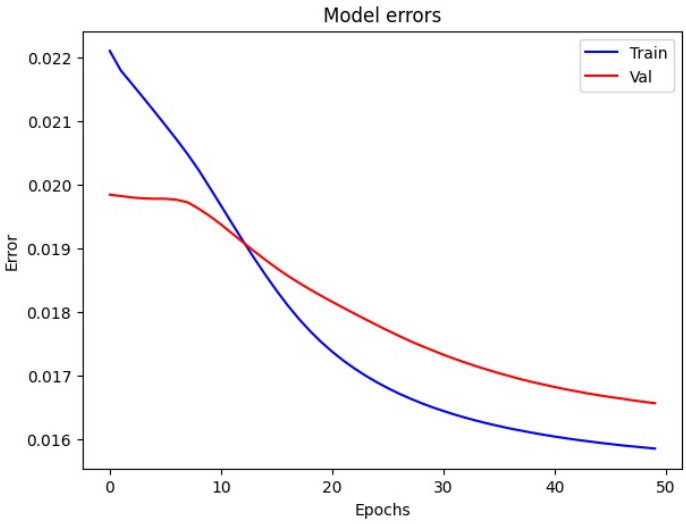

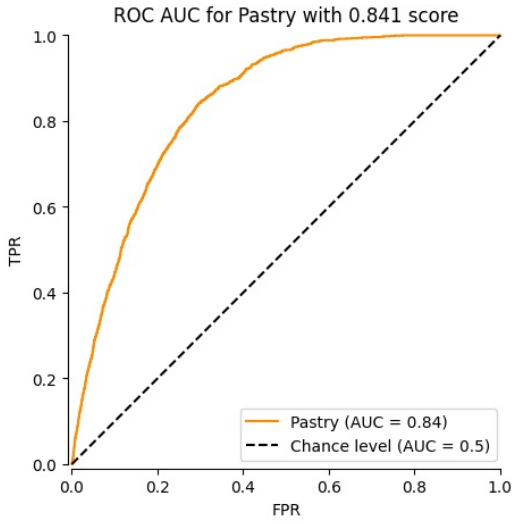

In [37]:
```
i = 1
plot_metrics(models[i],targets[i],errors[i][0],errors[i][1])
```

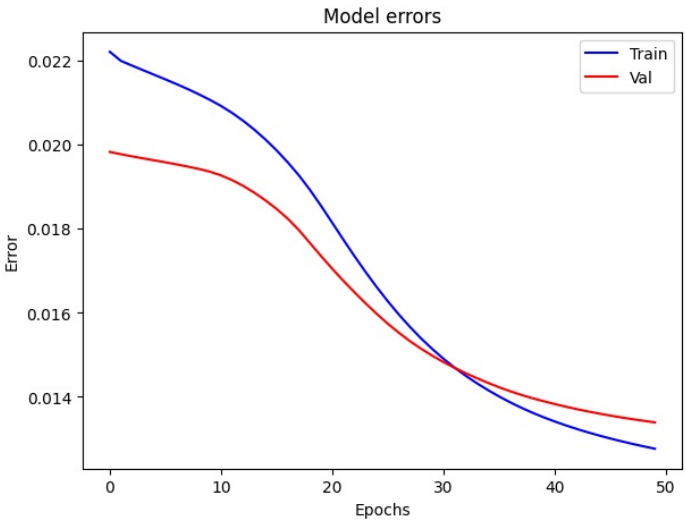

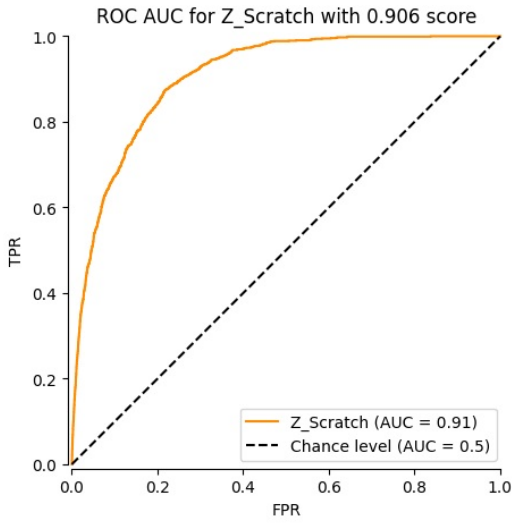

In [38]:
```
i = 2
plot_metrics(models[i],targets[i],errors[i][0],errors[i][1])
```

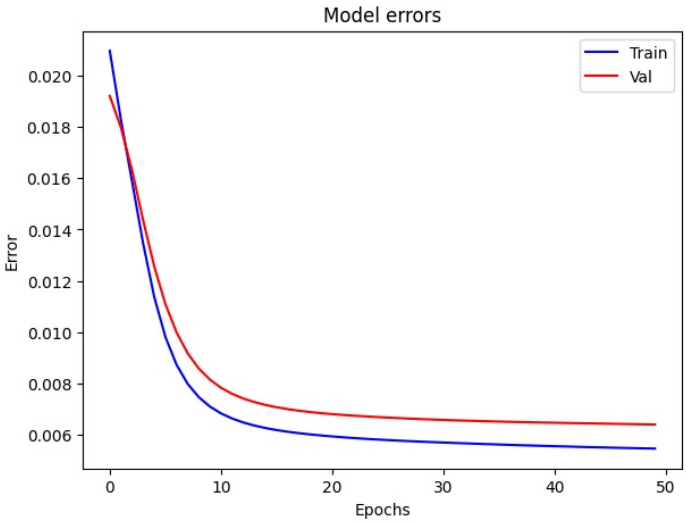

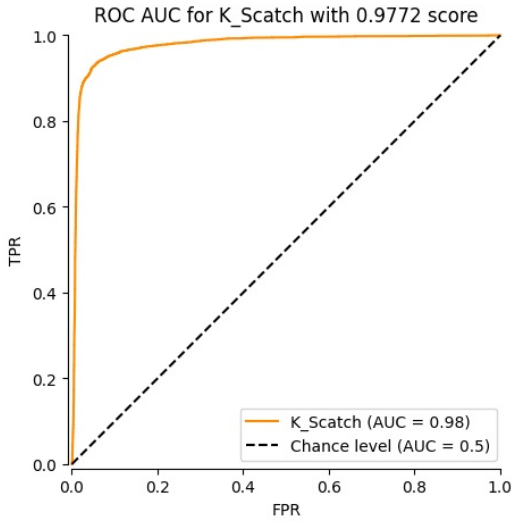

In [39]:
```
i = 3
plot_metrics(models[i],targets[i],errors[i][0],errors[i][1])
```

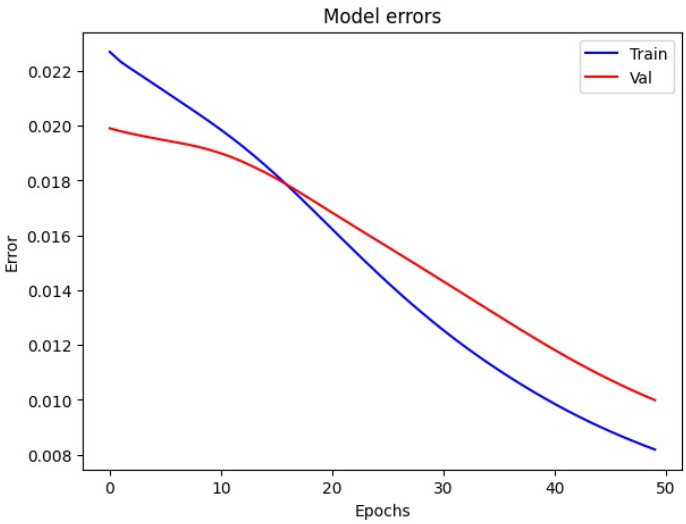

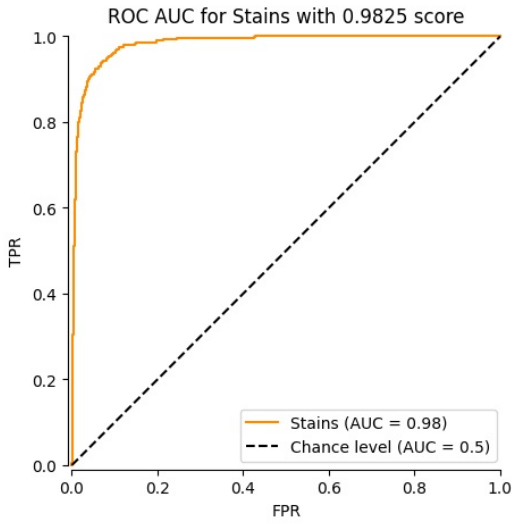

In [40]:
```
i = 4
plot_metrics(models[i],targets[i],errors[i][0],errors[i][1])
```

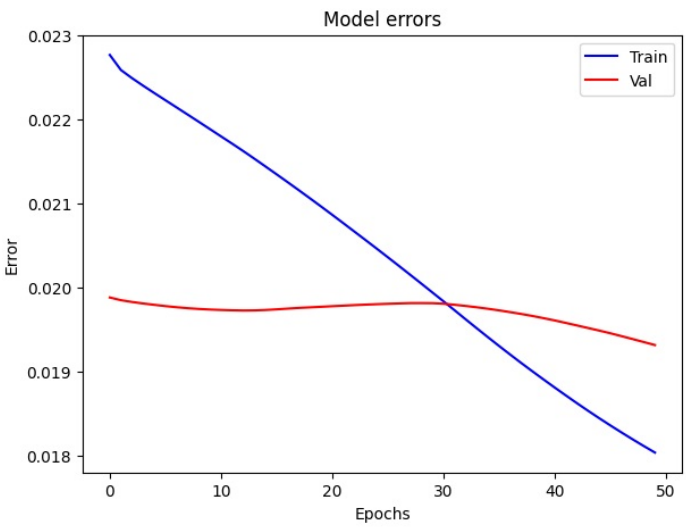

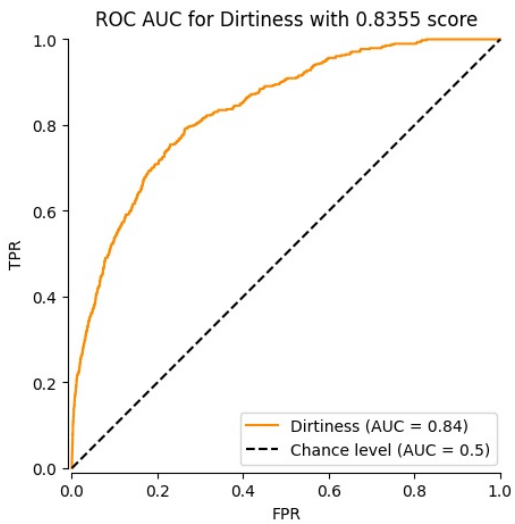

In [41]:
```
i = 5
plot_metrics(models[i],targets[i],errors[i][0],errors[i][1])
```

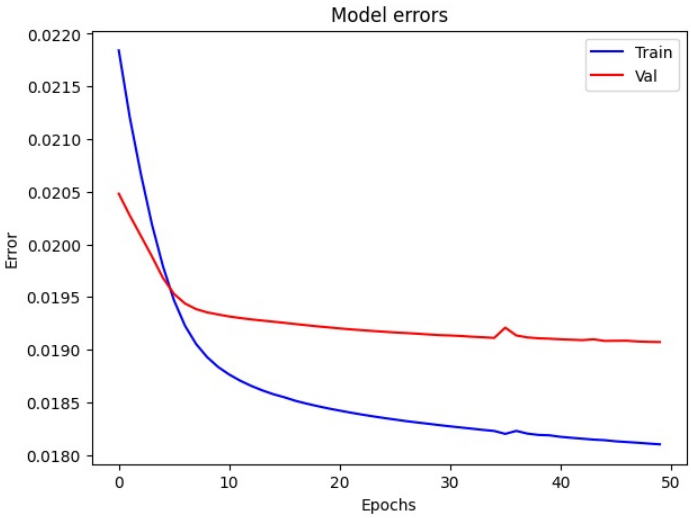

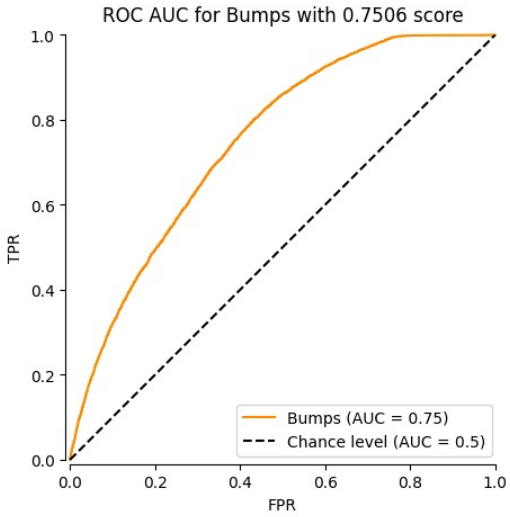

In [42]:
```
i = 6
plot_metrics(models[i],targets[i],errors[i][0],errors[i][1])
```

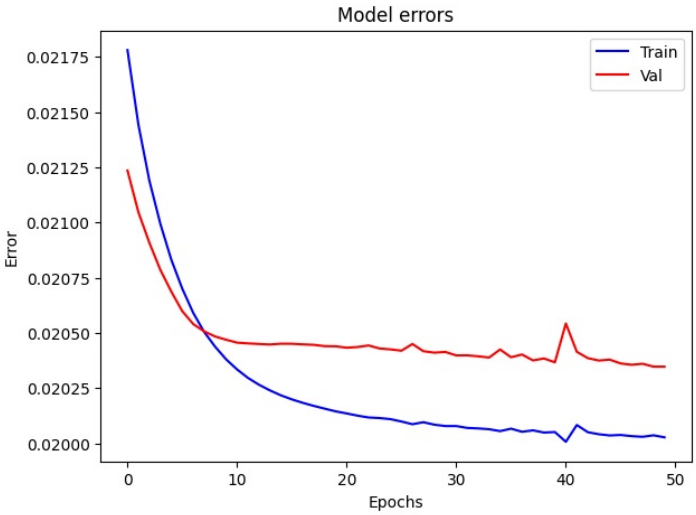

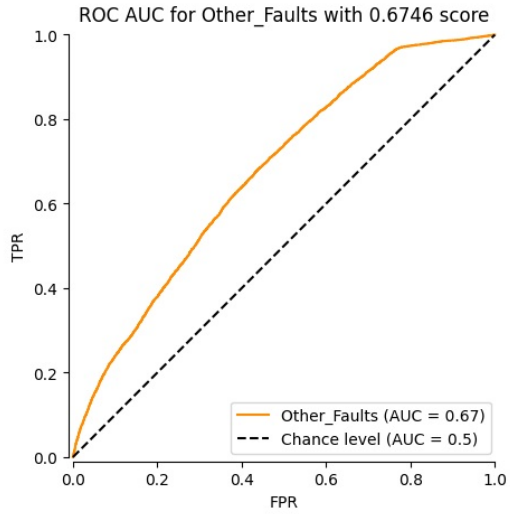

Выводы:

Первые 4 класса хорошо предсказываются построенной моделью.

С классами 'Bump','Other_Faults' и 'Dirtiness' стоит еще поработать, но пока оставлю так.

Предсказания для тестовой выборки

In [43]:
```
test_df = pd.read_csv('./ready_test.csv')
test_data = SteelPlateDataset(test_df[features])
test_loader = torch.utils.data.DataLoader(test_data, batch_size=len(test_df))

pred_df = test_df.copy()
pred_df['id'] = pd.read_csv('./test.csv')['id']
for i in range(len(targets)):
    with torch.no_grad():
        for d in test_loader:
            pred_df.loc[:,targets[i]] = models[i](d).numpy()
```

In [44]:
```
pred_df[['id']+targets].to_csv('./submission.csv',index=False)
```